

Reporte de Entendimiento de Datos (Data Understanding)

Proyecto: [Análisis de Absentismo Laboral](#)

Dataset: [Absenteeism_at_work](#)

Formato de origen: [.arff](#) / [SQL](#) / [CSV](#)

1. Resumen del Dataset

El conjunto de datos contiene registros de ausencia en una empresa brasileña entre julio de 2007 y julio de 2010. El objetivo principal es comprender los factores que influyen en el tiempo de ausencia (target) y clasificar las razones médicas y no médicas.

- **Número total de atributos:** 21 (20 predictores + 1 variable objetivo).
- **Variable Objetivo:** [Absenteeism_time_in_hours](#).
- **Unidad de análisis:** Registros individuales de ausencia por empleado.

2. Descripción de Atributos

2.1. Identificación y Temporalidad

Atributo	Tipo	Descripción	Observaciones
ID	Nominal	Identificador único del empleado.	36 valores distintos. Permite agrupar ausencias por individuo.
Month_of_absence	Real	Mes del año (1-12).	El valor '0' suele ser un error de dato o falta de registro.
Day_of_the_week	Nominal	Día en que inició la ausencia.	Codificado: Lunes(2) a Viernes(6). No incluye fines de semana.
Seasons	Nominal	Estación del año.	1:Verano, 2:Otoño, 3:Invierno, 4:Primavera.

2.2. Razones de Ausencia (Variable Crítica)

El atributo `Reason_for_absence` es categórico (0 al 28). Se divide en dos grandes grupos:

1. **Categorías CIE (1-21):** Enfermedades codificadas internacionalmente (ej. Infecciosas, Sistema Digestivo, etc.).
2. **Categorías Especiales (22-28):** Seguimiento médico, donación de sangre, consulta dental, ausencia injustificada, etc.
3. **Valor 0:** Generalmente representa error o registros sin causa definida.

2.3. Perfil del Empleado y Factores Sociales

- **Demografía:** Edad (`Age`), Educación (`Education`), Hijos (`Son`), Mascotas (`Pet`).
- **Salud:** Peso (`Weight`), Altura (`Height`), Índice de Masa Corporal (`Body_mass_index`).
- **Hábitos:** Bebedor social (`Social_drinker`) y Fumador social (`Social_smoker`).
- **Laboral:** Gasto de transporte (`Transportation_expense`), Distancia al trabajo (`Distance_from_Residence_to_Work`), Antigüedad (`Service_time`), Carga de trabajo promedio (`Work_load_Average/day_`) y cumplimiento de objetivos (`Hit_target`).

3. Calidad de Datos (Data Quality)

3.1. Detección de Duplicados Exactos

Como se discutió anteriormente, en este dataset es común encontrar filas donde **todas las columnas son iguales**.

- **Riesgo:** Si un empleado tiene dos registros idénticos de 4 horas de ausencia por "Consulta Dental" el mismo día, esto puede sesgar los modelos predictivos.
- **Acción recomendada:** Eliminar duplicados exactos antes del modelado.

3.2. Valores Nulos y Atípicos (Outliers)

- **Valores Nulos:** Según el encabezado `.arff`, muchas columnas permiten nulos (`YES`). Deben ser imputados o eliminados.
- **Outliers en horas:** La variable `Absenteeism_time_in_hours` suele tener una distribución con "cola larga" (pocas personas faltan muchísimas horas, mientras la mayoría falta 1-8 horas).

4. Relaciones Esperadas (Hipótesis)

1. **Carga Laboral:** Se espera que a mayor `Work_load_Average/day_`, aumenten las ausencias por estrés (Razones V o XVIII).
2. **Hábitos Sociales:** Los bebedores y fumadores sociales podrían presentar más ausencias de corta duración.

3. **Logística:** Empleados con mayor `Distance_from_Residence_to_Work` y `Transportation_expense` podrían tener una mayor frecuencia de retrasos o ausencias.