

Data Understanding — Tabla RRHH

Equipo 33 · 29/06/2026

Volumen datos

Indicador	Valor
Total de registros	740
ID únicos (empleados)	36
Registros por empleado (704 extra)	704
Combinaciones duplicadas	26
Filas sobrantes por duplicado	34

Los 704 registros extra son normales: cada fila es una solicitud de ausencia, no una persona. Los 34 duplicados sí son un error: el mismo registro repetido más de una vez.

Revisión por campo

Campo	Tipo	Problema detectado	Recomendación
id_registro*	—	No existe un identificador único de registro	Crear ID_absencia como clave primaria
ID	int	Identifica al empleado, no al registro	Renombrar a ID_empleado
Reason_absence	int	Códigos del 0 al 28 (falta el 20)	Diccionario confirmado: ver tabla de códigos más abajo
Month_absence	int	3 registros con valor 0 (mes no válido)	Revisar esos 3 registros
Day_week	int	Solo aparecen valores del 2 al 6	Confirmado: 2=Lunes ... 6=Viernes
Seasons	int	Valores del 1 al 4	Confirmar la equivalencia con el departamento (no documentada en la fuente)
Transportation_expense	int	Sin incidencias	—
Distance_Residence_Work	int	Sin incidencias	—
Service_time	int	Rango correcto	Antigüedad del empleado
Age	int	Rango correcto	—
Work_load_Average_day	varchar(512)	Debería ser numérico; usa coma decimal	Confirmar la unidad y convertir a número
Hit_target	int	Rango de 81 a 100	Confirmar qué representa esta variable
Disciplinary_failure	varchar(512)	Es un valor binario (1=sí, 0=no)	Convertir a booleano
Education	varchar(512)	Códigos del 1 al 4	Diccionario confirmado: ver tabla de códigos más abajo

Data Understanding — Tabla RRHH

Campo	Tipo	Problema detectado	Recomendación
Son	varchar(512)	Número de hijos, guardado como texto	Convertir a tipo entero
Social_drinker	varchar(512)	Es un valor binario (1=sí, 0=no)	Convertir a booleano
Social_smoker	varchar(512)	Es un valor binario (1=sí, 0=no)	Convertir a booleano
Pet	varchar(512)	Número de mascotas, guardado como texto	Convertir a tipo entero
Weight	int	Rango correcto	—
Height	int	Rango correcto	—
Body_mass_index	int	Rango correcto, coincide con el cálculo real	—
Absenteeism_hours	int	Rango de 0 a 120 horas	Variable objetivo (target) del dataset

Diccionario de códigos

Reason_absence

Código	Significado
1	Enfermedades infecciosas y parasitarias
2	Neoplasias (tumores)
3	Enfermedades de la sangre y del sistema inmunitario
4	Enfermedades endocrinas, nutricionales y metabólicas
5	Trastornos mentales y del comportamiento
6	Enfermedades del sistema nervioso
7	Enfermedades del ojo
8	Enfermedades del oído
9	Enfermedades del sistema circulatorio
10	Enfermedades del sistema respiratorio
11	Enfermedades del sistema digestivo
12	Enfermedades de la piel
13	Enfermedades del sistema musculoesquelético
14	Enfermedades del sistema genitourinario
15	Embarazo, parto y puerperio
16	Afecciones del periodo perinatal
17	Malformaciones congénitas
18	Síntomas y hallazgos clínicos no clasificados

Data Understanding — Tabla RRHH

Código	Significado
19	Lesiones y envenenamientos
20	Causas externas de morbilidad (sin registros en la tabla)
21	Factores que influyen en el estado de salud
22	Seguimiento de paciente
23	Consulta médica
24	Donación de sangre
25	Examen de laboratorio
26	Ausencia injustificada
27	Fisioterapia
28	Consulta dental

Day_week

Código	Día
2	Lunes
3	Martes
4	Miércoles
5	Jueves
6	Viernes

Education

Código	Nivel
1	Educación secundaria
2	Graduado
3	Postgrado
4	Máster o doctorado

Data Understanding — Tabla RRHH

A tener en cuenta

No hay clave primaria

ID identifica al empleado, no a la fila. Hace falta una columna nueva (ID_absencia) para identificar cada registro de forma única.

Una fila es una ausencia, no un día

Un mismo episodio puede durar varias horas o días (el máximo registrado es 120). No confundir fila con jornada.

Datos del empleado mezclados con los de la ausencia

Age, Education, Height, Weight y otros son datos fijos de la persona, no del episodio. Lo ideal sería tener una tabla aparte de Empleados (sugerencia de mejora)

El empleado ID 29 tiene valores distintos en varios de estos campos fijos. Hay que comprobar si es un cambio real o un error de entrada.

Duplicados exactos

26 combinaciones de registros están repetidas, sumando 34 filas de más. Error a corregir.

Columnas con tipo de dato incorrecto

Disciplinary_failure, Social_drinker y Social_smoker son booleanos guardados como texto. Son y Pet son números enteros guardados como texto.

Work_load_Average_day usa coma decimal y debería ser numérico.

RESUMEN:

Calidad general: regular-buena. No hay valores nulos y los rangos numéricos son coherentes, pero hay varios problemas de estructura y de tipo de dato por resolver.

Próximos pasos para la fase de Data Cleaning:

- Crear ID_absencia como clave primaria y renombrar ID a ID_empleado
- Eliminar las 34 filas duplicadas, dejando un solo registro por combinación
- Convertir las columnas con tipo incorrecto: booleano, entero o numérico según el caso
- Aplicar el diccionario de Reason_absence, Day_week y Education ya confirmado
- Pedir a RRHH el significado de Seasons
- Decidir qué hacer con los 3 registros de Month_absence = 0
- Revisar el caso del empleado ID 29
- Valorar separar los datos fijos del empleado en una tabla aparte