

StaySpain

Departamento de Análisis de Datos

Tourist Accommodation - Data Understanding

SPRINT 2

Proyecto: Análisis de Alojamientos Turísticos en España

Tabla: Tourist_Accommodation

Dataset de origen: raw_dataset_29_06_2026.csv

Elaborado por: Equipo de Analistas de Datos Junior

6 de julio de 2026

1. Familiarización con la Fuente de los Datos

1.1 Contexto del Negocio

StaySpain es una plataforma digital española que conecta anfitriones y viajeros en todo el territorio nacional. Los propietarios y gestores turísticos pueden publicar alojamientos y los usuarios pueden consultar opciones, reservar estancias y valorar su experiencia. La sede central se encuentra en Barcelona y la plataforma tiene presencia en ocho destinos del dataset: Barcelona, Madrid, Valencia, Sevilla, Malaga, Girona, Mallorca y Menorca.

1.2 Objetivo del Data Understanding del Sprint 2

El objetivo de esta fase es verificar si el dataset Tourist_Accommodation contiene la información necesaria para responder a las preguntas de negocio del Sprint 2, identificar los riesgos de calidad y los posibles sesgos que pueden afectar a cada análisis, y definir las comprobaciones metodológicas que deberán realizarse durante el EDA, la limpieza, la transformación y la interpretación de los resultados.

A diferencia del Sprint 1, centrado principalmente en promedios descriptivos por ciudad, el Sprint 2 requiere estudiar relaciones entre variables, comparar grupos de alojamientos y construir nuevas variables analíticas a partir de campos semiestructurados. Por ello, el Data Understanding incorpora desde el inicio una evaluación de cobertura, representatividad, calidad de medición, clasificación y posibles variables de confusión.

1.3 Preguntas de Negocio del Sprint 2

Perfil analítico	Pregunta de negocio
Marketing y Estrategia Comercial	¿Qué características de los alojamientos -equipamientos, capacidad y ubicación- están más relacionadas con los precios en cada ciudad?
Operaciones y Gestión de Inventario	¿Qué impacto tiene la opción de reserva instantánea, sin revisión del propietario, sobre la disponibilidad media en cada ciudad?
Experiencia del Cliente	¿Qué aspectos -precisión de los detalles, limpieza, check-in o comunicación- presentan las mayores diferencias entre los alojamientos mejor y peor valorados en la evaluación general?

1.4 Origen y Flujo de los Datos

Según la documentación de onboarding de StaySpain, los datos se originan en tres fuentes principales:

- Anuncios creados por anfitriones: características físicas, ubicación, servicios, condiciones y tarifas.
- Disponibilidad y opciones de reserva: calendarios publicados y configuración de reserva instantánea.
- Feedback de los viajeros: número de reseñas y puntuaciones de la experiencia.

Aunque el ecosistema de StaySpain integra información de reservas, el dataset analizado no contiene transacciones individuales de reserva, fechas de estancia ni duración de las reservas. Incluye disponibilidad publicada y la opción de reserva instantánea.

Los registros se actualizan semanalmente. Por este motivo, algunos apartment_id aparecen en más de una fecha de extracción. Estas filas representan instantáneas temporales del mismo alojamiento y no duplicados exactos.

2. Características y Alcance del Dataset

2.1 Dimensiones del Dataset

Indicador	Valor
Total de registros	7.001
Total de variables	35
Alojamientos únicos (apartment_id)	6.733

Indicador	Valor
Registros adicionales por apartment_id repetido	268
apartment_id con más de una observación	261
Duplicados exactos	0
Ciudades representadas	8

Verificación del esquema respecto al Sprint 1

La tabla contiene 35 columnas, no 34. Además, los 268 corresponden a registros adicionales generados por apartment_id repetidos; estos registros pertenecen a 261 alojamientos distintos.

2.2 Unidad de Análisis y Dimensión Temporal

La unidad de análisis prevista para las tres preguntas del Sprint 2 es el alojamiento turístico, identificado mediante apartment_id. Como las preguntas buscan describir relaciones y diferencias en el último estado disponible en el dataset, la alternativa metodológica más coherente es conservar la observación más reciente de cada apartment_id según insert_date.

En los registros repetidos se observan cambios en variables directamente relacionadas con el Sprint 2: 121 alojamientos modifican el precio, 158 modifican la lista de equipamientos, 22 cambian la opción de reserva instantánea y más de 200 presentan variaciones en alguno de los horizontes de disponibilidad. Esto confirma que las filas repetidas son snapshots y que no deben promediarse como si fueran alojamientos independientes.

La selección del último snapshot disponible no crea una fotografía plenamente contemporánea: las fechas más recientes de los 6.733 alojamientos se distribuyen entre 2017 y 2021. Esta desalineación temporal puede afectar especialmente a los análisis de precio y disponibilidad, por lo que insert_date deberá conservarse como variable de control.

Año del último snapshot	Alojamientos	% del total
2017	773	11,48 %
2018	1.910	28,37 %
2019	2.151	31,95 %
2020	1.631	24,22 %
2021	268	3,98 %

2.3 Población Objetivo y Subconjuntos Analíticos

La población objetivo operativa se define como los 6.733 alojamientos representados por su último snapshot disponible. Sin embargo, cada pregunta utilizará un subconjunto analítico distinto, por lo que el alcance de las conclusiones deberá expresarse con precisión.

Perfil	Subconjunto analítico	Alcance de inferencia
Marketing	Alojamientos con precio y características válidas.	Los resultados no representarán a los registros excluidos por precio o características ausentes.
Operaciones	Alojamientos con reserva instantánea y disponibilidad válidas.	Las variables esenciales están completas, pero las fechas de extracción no son contemporáneas.
Experiencia	Alojamientos evaluados con rating y cuatro componentes válidos.	Las conclusiones representan a alojamientos con reseñas, no necesariamente al conjunto completo.

Principio de interpretación

Una diferencia de tamaño de muestra, una cobertura desigual o un valor nulo no demuestran por sí mismos la existencia de sesgo. Se documentan como riesgos potenciales cuando pueden alterar sistemáticamente la composición del subconjunto analizado o la relación observada entre variables.

2.4 Distribución General por Ciudad

Ciudad	Registros en el dataset bruto
Barcelona	2.127
Madrid	1.446
Mallorca	1.144
Girona	1.125
Sevilla	361
Malaga	350
Valencia	307
Menorca	141

La representación de las ciudades es desigual. Barcelona concentra el mayor volumen y Menorca el menor. Esta diferencia deberá considerarse al comparar resultados y al interpretar análisis segmentados por ciudad.

2.5 Estructura de la Tabla

Las 35 variables se organizan en seis bloques temáticos. Las variables marcadas como relevantes para el Sprint 2 participan directamente en al menos una de las preguntas de negocio.

A) Identificación del Alojamiento

Campo	Descripción	Relevancia S2
apartment_id	Identificador único del alojamiento.	Todos
name	Nombre del anuncio.	Apoyo
description	Descripción textual del alojamiento.	Apoyo
host_id	Identificador del anfitrión.	No directa

B) Localización

Campo	Descripción	Relevancia S2
neighbourhood_name	Barrio o zona del alojamiento.	Marketing
neighbourhood_district	Distrito del alojamiento.	Marketing
country	País del alojamiento.	Control
city	Ciudad del alojamiento.	Todos

C) Características Físicas y Equipamientos

Campo	Descripción	Relevancia S2
room_type	Tipo de alojamiento.	Marketing
accommodates	Capacidad máxima de huéspedes.	Marketing
bathrooms	Número de baños.	Marketing
bedrooms	Número de habitaciones.	Marketing
beds	Número de camas.	Marketing
amenities_list	Lista de equipamientos y servicios.	Marketing

D) Precios y Disponibilidad

Campo	Descripción	Relevancia S2
price	Precio del alojamiento en euros.	Marketing
minimum_nights	Número mínimo de noches.	Apoyo
maximum_nights	Número máximo de noches.	Apoyo
has_availability	Indicador general de disponibilidad.	Control
availability_30	Días disponibles en los próximos 30 días.	Operaciones
availability_60	Días disponibles en los próximos 60 días.	Operaciones
availability_90	Días disponibles en los próximos 90 días.	Operaciones
availability_365	Días disponibles en los próximos 365 días.	Operaciones

E) Reseñas y Puntuaciones

Campo	Descripción	Relevancia S2
number_of_reviews	Número acumulado de reseñas.	Control
first_review_date	Fecha de la primera reseña.	Apoyo
last_review_date	Fecha de la última reseña.	Apoyo
review_scores_rating	Evaluación general documentada en escala 0-100.	Experiencia
review_scores_accuracy	Precisión de los detalles, escala documentada 0-10.	Experiencia
review_scores_cleanliness	Limpieza, escala documentada 0-10.	Experiencia
review_scores_checkin	Experiencia de check-in, escala documentada 0-10.	Experiencia
review_scores_communication	Comunicación con el anfitrión, escala documentada 0-10.	Experiencia
review_scores_location	Valoración de la ubicación, escala documentada 0-10.	Apoyo
review_scores_value	Relación calidad-precio, escala documentada 0-10.	Apoyo

F) Metadatos y Comportamiento

Campo	Descripción	Relevancia S2
is_instant_bookable	Permite reservar sin revisión previa del propietario.	Operaciones
reviews_per_month	Promedio mensual de reseñas.	Apoyo
insert_date	Fecha de extracción del snapshot.	Todos

2.6 Variables Necesarias por Perfil

Perfil	Variables	Función analítica
Marketing	price	Variable objetivo
Marketing	amenities_list	Equipamientos; requiere desagregación
Marketing	accommodates, bathrooms, bedrooms, beds, room_type	Capacidad y características físicas
Marketing	city, neighbourhood_name, neighbourhood_district	Segmentación geográfica
Operaciones	is_instant_bookable	Variable de comparación: Sí/No
Operaciones	availability_30, 60, 90 y 365	Resultados de disponibilidad
Operaciones	city	Segmentación geográfica
Experiencia	review_scores_rating	Criterio para definir mejor/peor valorados
Experiencia	accuracy, cleanliness, checkin, communication	Aspectos comparados
Experiencia	city, apartment_id	Segmentación y unidad de análisis

3. Limitaciones Identificadas y Riesgos de Calidad

3.1 Snapshots Semanales y Registros Repetidos

Se han identificado 261 apartment_id repetidos: 254 aparecen dos veces y 7 aparecen tres veces. En total existen 268 registros adicionales respecto al número de alojamientos únicos. Cada repetición está asociada a una fecha insert_date distinta, lo que confirma el carácter temporal de los registros.

Decisión metodológica propuesta

Para responder a preguntas sobre el último estado disponible en el dataset, conservar únicamente el snapshot más reciente por apartment_id. Mantener todos los snapshots solo sería adecuado para un análisis explícito de evolución temporal, que no forma parte del desafío actual.

3.2 Valores Nulos Relevantes para el Sprint 2

Campo	Nulos	%	Perfil afectado	Impacto
neighbourhood_district	2.760	39,42 %	Marketing	Muy alto
review_scores_checkin	1.341	19,15 %	Experiencia	Alto
review_scores_accuracy	1.336	19,08 %	Experiencia	Alto
review_scores_communication	1.332	19,03 %	Experiencia	Alto
review_scores_cleanliness	1.330	19,00 %	Experiencia	Alto
review_scores_rating	1.327	18,95 %	Experiencia	Alto
price	131	1,87 %	Marketing	Medio
bathrooms	32	0,46 %	Marketing	Bajo
bedrooms	29	0,41 %	Marketing	Bajo
amenities_list	17	0,24 %	Marketing	Bajo
beds	3	0,04 %	Marketing	Bajo
is_instant_bookable	0	0,00 %	Operaciones	Nulo
availability_30/60/90/365	0	0,00 %	Operaciones	Nulo

3.2.1 Cobertura Geográfica de neighbourhood_district

Los nulos de neighbourhood_district no están distribuidos aleatoriamente. El campo está completo en Barcelona, Madrid, Sevilla y Valencia, pero es 100 % nulo en Girona, Malaga, Mallorca y Menorca. Por tanto, no puede utilizarse como nivel geográfico común para las ocho ciudades.

Ciudad	% nulo en distrito	Distritos distintos
Barcelona	0,00 %	10
Madrid	0,00 %	21
Sevilla	0,00 %	11
Valencia	0,00 %	19
Girona	100,00 %	0
Malaga	100,00 %	0
Mallorca	100,00 %	0
Menorca	100,00 %	0

Para el análisis de ubicación se recomienda utilizar city en todas las comparaciones y neighbourhood_name como nivel local común. neighbourhood_district podrá utilizarse únicamente como análisis complementario en las cuatro ciudades donde está informado.

Aunque neighbourhood_name no presenta valores nulos, contiene 478 categorías distintas en el último snapshot y numerosos grupos con pocos alojamientos. Antes de comparar precios se deberá establecer un tamaño mínimo de muestra por zona o agrupar categorías poco frecuentes para evitar conclusiones inestables.

3.2.2 Nulos de Reseñas

Los campos review_scores_* presentan aproximadamente un 19 % de valores nulos. Entre los 1.274 alojamientos sin review_scores_rating, 1.202 (94,35 %) no tienen informadas first_review_date, last_review_date ni reviews_per_month; además, 1.200 (94,19 %) tienen number_of_reviews igual a 0. Esto indica que la mayoría corresponde a alojamientos sin historial de valoraciones, aunque existen excepciones que deberán revisarse.

Patrón entre alojamientos sin rating	Alojamientos	% rating nulo
Sin fechas ni reviews_per_month	1.202	94,35 %
Con los tres indicadores informados	71	5,57 %
Patrón mixto	1	0,08 %
number_of_reviews igual a 0	1.200	94,19 %
number_of_reviews superior a 0	74	5,81 %

Tratamiento recomendado

No imputar las puntuaciones de reseñas. Conservar los alojamientos sin reseñas en el dataset maestro, pero excluirlos de la comparación entre alojamientos mejor y peor valorados. Considerar number_of_reviews como variable de control y realizar un análisis de sensibilidad según el volumen de reseñas.

3.2.3 Cobertura de Valoraciones en el Último Snapshot

Tras conservar el último snapshot por alojamiento, 5.459 de los 6.733 alojamientos (81,08 %) disponen de review_scores_rating válido. Para la comparación completa del perfil de Experiencia, 5.443 alojamientos (80,84 %) tienen simultáneamente rating, accuracy, cleanliness, check-in y communication.

Ciudad	Alojamientos	Rating válido	Cobertura
Barcelona	2.041	1.697	83,15 %
Girona	1.085	754	69,49 %
Madrid	1.396	1.194	85,53 %
Malaga	339	310	91,45 %
Mallorca	1.096	794	72,45 %
Menorca	138	116	84,06 %
Sevilla	341	315	92,38 %
Valencia	297	279	93,94 %

La cobertura no es homogénea: Girona y Mallorca presentan los porcentajes más bajos, mientras que Valencia, Sevilla y Malaga superan el 91 %. En consecuencia, el subconjunto evaluado modifica ligeramente la representación territorial y debe analizarse antes de generalizar resultados al total de alojamientos.

La cobertura también deberá revisarse por room_type, precio y volumen de reseñas. Las categorías pequeñas, como Shared room y Hotel room, requieren especial cautela porque sus porcentajes pueden ser inestables aun cuando la cobertura aparente sea alta.

3.3 Formatos, Escalas y Consistencia Semántica

Campo	Situación observada	Acción pendiente
price	Númérico, 131 nulos, rango observado 60-6.071.	Validar unidad, distribución y outliers antes de correlaciones.
amenities_list	Texto separado por comas; 310 etiquetas distintas.	Parsear, limpiar y crear variables de presencia/conteo.
amenities_list	1.523 apariciones de etiquetas “translation missing”.	Eliminar o recodificar etiquetas no informativas.
is_instant_bookable	Valores VERDADERO/FALSO.	Estandarizar a booleano o 1/0.
has_availability	Solo VERDADERO y 550 nulos.	No discrimina grupos; revisar su utilidad.
review_scores_rating	Valores observados 200-1.000.	Dividir por 10 para obtener la escala documentada 0-100.
Otros review_scores_*	Valores observados 20-100.	Dividir por 10 para obtener la escala documentada 0-10.
Fechas	Texto con formato día/mes/año.	Convertir con dayfirst=True y validar coherencia.
Campos textuales	Presencia del carácter de sustitución U+FFFD.	Investigar y corregir la codificación antes de analizar texto.

3.4 Limitaciones Específicas por Pregunta de Negocio

3.4.1 Marketing y Estrategia Comercial

- amenities_list no está normalizada: un alojamiento puede contener decenas de equipamientos dentro de una sola cadena de texto.
- Las etiquetas presentan errores de traducción y caracteres dañados, lo que puede fragmentar categorías equivalentes.
- neighbourhood_district no está disponible para la mitad de las ciudades; la comparación territorial debe adaptarse.
- neighbourhood_name tiene alta cardinalidad y algunos grupos pequeños; se deberá exigir un mínimo de alojamientos por categoría o agrupar zonas poco frecuentes.
- El precio presenta una distribución amplia y posibles valores extremos. Una correlación simple puede ser sensible a outliers y a diferencias entre tipos de alojamiento.
- La asociación entre características y precio no implica causalidad; otras variables no observadas pueden influir.

3.4.2 Operaciones y Gestión de Inventario

- `is_instant_bookable` está completo y contiene dos categorías, con representación en todas las ciudades.
- Las cuatro variables de disponibilidad están completas y respetan sus rangos teóricos: 0-30, 0-60, 0-90 y 0-365.
- Los cuatro horizontes tienen escalas diferentes. Para compararlos entre sí deberá calcularse una tasa de disponibilidad normalizada: $\text{availability}_n / n \times 100$.
- La disponibilidad publicada no equivale necesariamente a ocupación o demanda real: un día no disponible puede estar reservado, bloqueado por el anfitrión o fuera de servicio.
- El término “impacto” deberá interpretarse como diferencia o asociación observada, no como efecto causal.

Distribución Inicial de Reserva Instantánea por Ciudad

Ciudad	FALSO	VERDADERO	Total
Barcelona	1.112	929	2.041
Girona	453	632	1.085
Madrid	661	735	1.396
Malaga	110	229	339
Mallorca	460	636	1.096
Menorca	72	66	138
Sevilla	113	228	341
Valencia	162	135	297

Los dos grupos están presentes en las ocho ciudades, pero su composición no es homogénea. Antes de comparar la disponibilidad media se deberán reportar los tamaños de cada grupo por ciudad y evitar conclusiones basadas en grupos insuficientes.

3.4.3 Experiencia del Cliente

- La definición de “mejor” y “peor” valorados debe establecerse después de revisar la distribución de `review_scores_rating`.
- Las escalas deben normalizarse antes de comparar las variables.
- Los alojamientos sin reseñas no deben incorporarse a los cálculos ni recibir valores imputados.
- La comparación debe considerar medias y medianas debido a la concentración de puntuaciones altas y a la posible falta de normalidad.
- La significación estadística debe complementarse con un tamaño del efecto para valorar la relevancia práctica.
- El número de reseñas puede afectar a la estabilidad de la puntuación general. Se recomienda comparar los resultados con y sin un umbral mínimo de reseñas o por tramos de volumen.

4. Posibles Sesgos y Limitaciones de los Datos

La identificación de sesgos comienza en Data Understanding. En esta fase no se afirma que todos los riesgos estén presentes de forma demostrada; se documentan mecanismos plausibles que podrían distorsionar la muestra, la medición o la interpretación. Las comprobaciones cuantitativas se desarrollarán durante el EDA y los análisis específicos.

La terminología se adapta del Catalogue of Bias, especialmente de los conceptos de sesgo de selección, sesgo de no respuesta, sesgo de información, clasificación errónea y confusión.

4.1 Mapa de Riesgos de Sesgo y Plan de Comprobación

Riesgo	Perfil	Origen / impacto posible	Comprobación prevista
Selección y cobertura de reseñas	Experiencia	Los alojamientos sin puntuaciones quedan fuera del análisis de satisfacción.	Comparar cobertura por ciudad, <code>room_type</code> , precio y características; limitar la inferencia a alojamientos evaluados.
Autoselección / no respuesta	Experiencia	La decisión de dejar una reseña puede relacionarse con experiencias especialmente positivas o negativas.	Documentar que no existen datos de huéspedes que no reseñaron; no puede medirse directamente.

Riesgo	Perfil	Origen / impacto posible	Comprobación prevista
Representatividad desigual	Todos	Las ciudades y algunas categorías tienen tamaños muy diferentes; la precisión no será homogénea.	Reportar n por grupo y ciudad, evitar inferencias con celdas pequeñas y usar intervalos o análisis de sensibilidad.
Información y medición	Todos	Ratings subjetivos, etiquetas dañadas de amenities y disponibilidad que no equivale a ocupación real.	Normalizar escalas, limpiar categorías y describir exactamente qué mide cada variable.
Clasificación errónea	Marketing / Experiencia	Errores al desagregar amenities o al definir mejor/peor valorados pueden cambiar los resultados.	Validar reglas de parsing; comparar cuartiles con umbrales alternativos.
Confusión	Todos	Ciudad, tipo, precio, ubicación, fecha y número de reseñas pueden explicar parte de las asociaciones.	Estratificar, ajustar cuando sea viable y comprobar consistencia entre subgrupos.
Desalineación temporal	Marketing / Operaciones	Los últimos snapshots disponibles pertenecen a años distintos (2017-2021).	Conservar insert_date, describir su distribución y realizar sensibilidad por periodo o cohorte temporal.
Tamaño de muestra insuficiente	Todos	Grupos pequeños pueden producir resultados inestables; muestras grandes pueden generar p-valores pequeños con efectos irrelevantes.	Definir mínimos por categoría y acompañar significación con tamaños del efecto.

4.2 Riesgos Específicos por Perfil

4.2.1 Marketing y Estrategia Comercial

- La ausencia de price o de características puede generar un subconjunto distinto del total si los faltantes se concentran en determinadas ciudades o tipos de alojamiento.
- La cobertura desigual de neighbourhood_district y la alta cardinalidad de neighbourhood_name pueden favorecer comparaciones territoriales no equivalentes.
- La codificación defectuosa de amenities_list puede dividir un mismo equipamiento en categorías diferentes o eliminar señales relevantes.
- Las asociaciones con precio pueden estar confundidas por room_type, capacidad, ubicación, fecha del snapshot y otras variables no observadas.
- Los precios proceden de periodos distintos; no deben compararse como si todos reflejaran el mismo mercado temporal.

4.2.2 Operaciones y Gestión de Inventario

- La opción de reserva instantánea no se asigna aleatoriamente; puede estar relacionada con ciudad, tipo de alojamiento, estrategia del anfitrión, precio u otras características.
- La disponibilidad publicada es una medida imperfecta de ocupación o demanda y puede producir sesgo de medición si se interpreta como reserva efectiva.
- La distribución entre VERDADERO y FALSO varía por ciudad; se comprobará el tamaño de ambos grupos antes de comparar medias.
- La disponibilidad y la configuración de reserva pertenecen a fechas de extracción diferentes entre alojamientos, lo que introduce riesgo temporal.

4.2.3 Experiencia del Cliente

- Los resultados excluyen a los alojamientos sin reseñas y, por tanto, no representan automáticamente a toda la oferta de StaySpain.
- Las puntuaciones son subjetivas y pueden reflejar expectativas distintas según ciudad, precio, ubicación y tipo de alojamiento.
- No puede descartarse autoselección: los huéspedes con experiencias extremas podrían tener mayor propensión a valorar.
- La estabilidad de la puntuación depende del número de reseñas; un rating basado en pocas observaciones es más incierto.

- La clasificación Best/Worst puede variar según el criterio elegido; se evaluará el equilibrio de los grupos general y por ciudad.
- Las diferencias en cleanliness, communication, check-in o accuracy pueden estar confundidas por city, room_type, price, location y number_of_reviews.

4.3 Alcance de las Conclusiones

Regla de comunicación

Los resultados se presentarán como asociaciones, diferencias o patrones observados. No se afirmará causalidad directa. Cuando la cobertura sea incompleta o los grupos sean pequeños, se limitará explícitamente la generalización de las conclusiones.

5. Adecuación del Dataset para el Sprint 2

Perfil	Adecuación	Conclusión
Marketing y Estrategia Comercial	Sí, con transformación adicional	Contiene precio, equipamientos, capacidad y ubicación. Requiere corregir codificación, desagregar amenities_list, evaluar faltantes, validar outliers y controlar la fecha del snapshot.
Operaciones y Gestión de Inventario	Sí, con cautela temporal	Contiene is_instant_bookable, disponibilidad en cuatro horizontes y ciudad. Debe controlarse la fecha del snapshot y la composición de los grupos.
Experiencia del Cliente	Sí, para alojamientos evaluados	Contiene evaluación general y los cuatro aspectos. Requiere normalización, análisis de cobertura y exclusión no imputada de registros sin reseñas.
Conjunto del equipo	Sí, dentro del alcance del ejercicio	No se necesita otra fuente para abordar las preguntas dentro del alcance descriptivo y asociativo. Es necesario generar un dataset maestro limpio con una fila por alojamiento.

Conclusión de viabilidad

El dataset bruto es suficiente para abordar las tres preguntas dentro del alcance descriptivo y asociativo del ejercicio, pero no debe analizarse directamente. No permite demostrar causalidad, medir reservas reales ni representar un único mercado contemporáneo. Antes del análisis deberán resolverse los snapshots, las escalas, la codificación, los booleanos y los equipamientos; además, se evaluarán cobertura, representatividad, no contemporaneidad temporal, clasificación y posibles variables de confusión.

6. Decisiones Metodológicas Previas al EDA

Decisión	Criterio propuesto
Unidad de análisis	Un alojamiento turístico por apartment_id.
Snapshots	Conservar el registro más reciente según insert_date.
Precio	Mantener como numérico; investigar nulos, asimetría y outliers antes de decidir tratamiento.
Equipamientos	Separar amenities_list por comas; limpiar etiquetas; crear amenities_count y variables binarias para equipamientos relevantes.
Capacidad	Validar rangos de accommodates, bathrooms, bedrooms y beds; no imputar automáticamente sin justificación.

Decisión	Criterio propuesto
Ubicación	Usar city como nivel común y neighbourhood_name como nivel local; district solo donde exista. Establecer un mínimo de observaciones por zona.
Reserva instantánea	Convertir VERDADERO/FALSO a variable booleana o 1/0.
Disponibilidad	Comparar alojamientos con y sin reserva instantánea dentro de cada horizonte. Para comparar horizontes entre sí, calcular $\text{availability_n} / n \times 100$.
Puntuaciones	Normalizar rating a 0-100 y componentes a 0-10.
Sin reseñas	Excluir únicamente del análisis de experiencia; conservar en el dataset maestro. Controlar la estabilidad mediante number_of_reviews.
Mejor/peor valorados	Definir tras estudiar la distribución; comparar cuartiles como opción principal y umbrales como sensibilidad.
Cobertura y representatividad	Comparar el dataset completo con cada subconjunto analítico por ciudad, room_type, precio y volumen de reseñas.
Equilibrio de grupos	Reportar tamaños de muestra por ciudad y categoría; establecer mínimos antes de inferir.
Confusión	Evaluar city, room_type, price, location, number_of_reviews e insert_date según el perfil analítico.
Sensibilidad temporal	Conservar insert_date y comprobar si las conclusiones cambian por año o periodo de extracción.
Inferencia	Utilizar lenguaje de asociación/diferencia; no afirmar causalidad con datos observacionales.

7. Áreas de Interés Inicial y Prioridad

Área de interés	Descripción	Prioridad
Factores asociados al precio	Comparar equipamientos, capacidad y ubicación dentro de cada ciudad.	Alta
Reserva instantánea y disponibilidad	Comparar disponibilidad media entre alojamientos con y sin reserva instantánea.	Alta
Brechas de experiencia	Identificar el aspecto con mayor diferencia entre extremos de valoración.	Alta
Calidad de texto y codificación	Corregir caracteres dañados y etiquetas no traducidas.	Alta
Cobertura geográfica	Adaptar el nivel de ubicación a la disponibilidad real por ciudad.	Alta
Sensibilidad a outliers	Evaluar métodos robustos para precio y puntuaciones.	Alta
Cobertura y representatividad	Comparar la composición de los subconjuntos analíticos con el total.	Alta
Riesgos de sesgo	Evaluar selección, medición, clasificación, confusión y no contemporaneidad.	Alta
Evolución temporal	Posible uso futuro de todos los snapshots.	Media

8. Conclusión

El dataset Tourist_Accommodation contiene las variables necesarias para los tres análisis del Sprint 2. Marketing deberá transformar equipamientos, capacidad y ubicación; Operaciones conservar is_instant_bookable y los cuatro horizontes de disponibilidad; y Experiencia del Cliente mantener la evaluación general y sus componentes.

Se recomienda ampliar el pipeline existente para generar un dataset maestro limpio con 6.733 alojamientos únicos, del que cada perfil obtenga su subconjunto reproducible. Las principales limitaciones son la codificación de amenities_list, la cobertura territorial parcial, los alojamientos sin reseñas, la subjetividad de las puntuaciones, la ausencia de transacciones individuales y la falta de contemporaneidad de los últimos snapshots. Los resultados deberán interpretarse como asociaciones, no como relaciones causales.

Nota de trazabilidad: los resultados numéricos se obtuvieron con Data_Understanding_06_07_2026.ipynb; el contexto y los criterios se basan en el Guió desafiament N°2, el Onboarding de alojamientos, las Instrucciones para Analistas de Datos Junior, el Data Understanding del Sprint 1 y el Catalogue of Bias. Este último se utilizó como marco para identificar riesgos de selección, no respuesta, información, clasificación y confusión; la diferencia temporal se describe como falta de contemporaneidad de los snapshots.