

StaySpain

Departamento de Análisis de Datos

Tourist Accommodation - Data Understanding **SPRINT 3**

Proyecto: Análisis de Alojamientos Turísticos en España

Tabla: Tourist_Accommodation

Dataset de origen: raw_dataset_13_07_2026.csv

Elaborado por: Equipo de Analistas de Datos Junior

13 de julio de 2026

1. Contexto y Preguntas de Negocio

StaySpain opera en ocho ciudades (Barcelona, Madrid, Valencia, Sevilla, Málaga, Girona, Mallorca y Menorca). El Sprint 3 cambia el foco: potencial de optimización por zona, efecto de las características físicas sobre la disponibilidad, y relación precio-satisfacción. Se revisa la relevancia de cada variable desde cero.

Perfil	Pregunta de negocio
Marketing	¿Qué ciudades y barrios presentan mayor potencial de optimización considerando reseñas, puntuación de zona y noches mínimas/máximas?
Operaciones	¿Cómo afectan habitaciones, baños y camas a la disponibilidad media? ¿Difiere entre ciudades?
Experiencia	¿Existe relación entre precio y satisfacción general? ¿Cómo varía por ciudad?

El dataset no contiene transacciones individuales de reserva. Se actualiza semanalmente, por lo que algunos apartment_id tienen más de un snapshot.

2. Dimensiones y Alcance

Indicador	Sprint 2 (06/07)	Sprint 3 (13/07)
Total de registros	8.000	10.000
Alojamientos únicos	7.693	9.650
apartment_id repetidos	299	342
Registros adicionales	307	350
Duplicados exactos	0	0
Variables	35	35

Crecimiento: +25 % en registros y +25,4 % en alojamientos únicos respecto al Sprint 2, con proporciones por ciudad similares. Mismo esquema de 35 columnas. A diferencia de una versión previa del archivo revisada por el equipo, esta carga no presenta filas con corrupción de columnas.

Distribución por ciudad (bruto)

Ciudad	Registros	Ciudad	Registros
Barcelona	2.825	Sevilla	524
Madrid	2.202	Málaga	520
Mallorca	1.644	Valencia	528
Girona	1.533	Menorca	224

Snapshots por año (último snapshot por alojamiento, n = 9.650)

2017	2018	2019	2020	2021
773 (8,0%)	2.002 (20,7%)	3.274 (33,9%)	3.026 (31,4%)	575 (6,0%)

Igual que en el Sprint 2, las fechas van de 2017 a 2021: insert_date debe conservarse como variable de control en Marketing y Operaciones.

Cambios entre snapshots (342 alojamientos con más de una observación)

Variable	Alojamientos que cambian	Variable	Alojamientos que cambian
price	156	beds	44
amenities_list	214	bathrooms	12
availability_30	262	bedrooms	11
is_instant_bookable	26		

bedrooms, bathrooms y beds — centrales para la pregunta de Operaciones este sprint — también cambian entre snapshots. Aplicar el mismo criterio de "conservar el último snapshot" que en el resto de variables.

Variables necesarias por perfil

Perfil	Variables clave	Función
Marketing	neighbourhood_name/district, number_of_reviews, review_scores_location, minimum/maximum_nights, city	Demanda, importancia de zona y condiciones de reserva
Operaciones	bedrooms, bathrooms, beds, availability_30/60/90/365, city	Explicativas físicas y resultado de disponibilidad
Experiencia	price, review_scores_rating, city	Relación precio-satisfacción

Cambio de foco: room_type, amenities_list e is_instant_bookable (protagonistas en el Sprint 2) ya no son variables directas. bedrooms, bathrooms, beds, review_scores_location y minimum/maximum_nights pasan a ser centrales.

3. Hallazgos y Riesgos de Calidad

3.1 Nulos relevantes

Campo	Nulos	%	Perfil
neighbourhood_district	3.921	39,2%	Marketing
review_scores_location	2.724	27,2%	Marketing
review_scores_rating	2.709	27,1%	Experiencia
review_scores_* (resto)	~2.712-2.724	~27,1-27,2%	Apoyo
price	254	2,5%	Experiencia
bathrooms / bedrooms / beds	45-74	<1%	Operaciones

Frente al Sprint 2: los nulos de review_scores_* suben de ~21% a ~27,1%, y price de 2,14% a 2,54%. A confirmar en EDA si es tendencia real o efecto de la muestra nueva.

Cobertura geográfica y de reseñas

- neighbourhood_district: 100% nulo en Girona, Málaga, Mallorca y Menorca (igual patrón que Sprint 2). neighbourhood_name: 521 categorías, sin nulos.
- 20 alojamientos con nulos parciales en review_scores_* (patrón mixto, a revisar en Cleaning); el resto son nulos estructurales consistentes en las 7 puntuaciones a la vez.
- 108 alojamientos con rating nulo pese a number_of_reviews > 0 — inconsistencia menor a resolver en Cleaning.

Cobertura combinada precio + rating por ciudad (clave para Experiencia)

Ciudad	Cobertura	Ciudad	Cobertura
Sevilla	85,6%	Barcelona	75,7%
Valencia	82,8%	Menorca	64,7%
Málaga	82,1%	Girona	60,3%
Madrid	76,2%	Mallorca	59,0%

Girona y Mallorca tienen la menor cobertura combinada: reportar el tamaño de muestra efectivo junto a cualquier resultado de Experiencia por ciudad.

3.2 Formatos y escalas

Campo	Hallazgo	Acción
price	Rango 60-28.571€ (máx. 6.071€ en Sprint 2)	Validar los nuevos extremos antes de correlacionar
maximum_nights	1.125 en 61,3% de los casos	Posible valor por defecto de la plataforma; pendiente de validar, no confirmado
maximum_nights > 31 días	79,2% de los casos	Gran parte coincide con el posible valor por defecto; validar antes de excluirlo del indicador legal
minimum_nights > 31 días	288 casos	Sí son condición de reserva real, a revisar
bedrooms/bathrooms/beds	0-50 / 0-13 / 0-30	Validar valores más altos antes de correlacionar
review_scores_rating	200-1.000	Dividir entre 10 (escala 0-100)
Otros review_scores_*	20-100	Dividir entre 10 (escala 0-10)
is_instant_bookable / has_availability	VERDADERO/FALSO y VERDADERO/nulo (550 nulos)	is_instant_bookable: estandarizar a 1/0. has_availability: mantener los nulos como estado desconocido, no imputar
description	6.869 registros con carácter dañado (U+FFFD)	Corregir codificación antes de analizar texto
amenities_list	959 apariciones de "translation missing"	No es variable directa este sprint

Hallazgo a validar en Marketing: el 61% de maximum_nights = 1.125 podría ser un valor por defecto de la plataforma cuando no se fija máximo, no necesariamente un incumplimiento del límite legal de 31 días. Pendiente de confirmar antes de tratarlo como tal.

4. Riesgos de Sesgo

Riesgo	Perfil	Comprobación prevista
Posible valor por defecto en maximum_nights	Marketing	Validar si 1.125 es un valor por defecto de la plataforma antes de tratarlo como "sin política definida"
Cobertura desigual de reseñas/zona	Marketing / Experiencia	Comparar cobertura por ciudad; limitar inferencia
Representatividad desigual	Todos	Reportar n por ciudad; evitar celdas pequeñas (Menorca = 224 registros brutos)

Riesgo	Perfil	Comprobación prevista
Confusión (room_type, capacidad, precio)	Operaciones / Experiencia	Estratificar por ciudad; controlar cuando sea viable
Desalineación temporal	Todos	Conservar insert_date; sensibilidad por año

Regla de comunicación: los resultados se presentan como asociaciones o diferencias, nunca como causalidad.

5. Decisiones Clave Antes de Cleaning, Transformation y Análisis

Decisión	Criterio
Snapshots	Conservar el registro más reciente por apartment_id según insert_date
maximum_nights = 1.125	Validar si es un valor por defecto de la plataforma antes de tratarlo como "sin política definida"; no asumirlo como incumplimiento legal sin confirmar
Ubicación	city + neighbourhood_name; district solo en las 4 ciudades donde existe
Puntuaciones	Rating ÷ 10 → escala 0-100; resto ÷ 10 → escala 0-10
Disponibilidad	Normalizar como tasa: availability_n / n × 100
Sin reseñas	Excluir del análisis de Experiencia (depende de rating). En Marketing, mantener estos alojamientos: number_of_reviews = 0 es información válida sobre demanda, no un dato a descartar
Segmentación por ciudad	Obligatoria en Operaciones y Experiencia (lo piden las preguntas)

6. Conclusión

El dataset del 13 de julio (10.000 registros, 9.650 alojamientos únicos) es adecuado para las tres preguntas del Sprint 3. Prioridades antes de Cleaning, Transformation y los análisis posteriores, de mayor a menor urgencia:

- Validar si maximum_nights = 1.125 es realmente un valor por defecto de la plataforma antes de calcular cualquier indicador de restricción legal.
- Corregir las escalas de review_scores_* (÷10).
- Resolver snapshots duplicados conservando el más reciente.
- Reportar cobertura y tamaño de muestra por ciudad en Marketing, Operaciones y Experiencia.
- Corregir la codificación de texto (U+FFFD) antes de cualquier análisis de description.

Nota de trazabilidad: cálculos sobre raw_dataset_13_07_2026.csv (10.000 registros). Una versión previa del archivo, con 9.854 registros y una fila con corrupción de columnas, fue descartada y sustituida por esta antes de completar este documento. Criterios basados en el Guió desafiament N°3 y los Data Understanding de los Sprints 1 y 2.