

StaySpain

Departamento de Análisis de Datos

Tourist Accommodation — Data Understanding

Proyecto: Análisis de Alojamientos Turísticos en España

Tabla: Tourist_Accommodation

Elaborado por:

Equipo de Analistas de Datos Junior

Junio – Julio 2026

1. Familiarización con la Fuente de los Datos

1.1 Contexto del Negocio

StaySpain es una plataforma digital española que conecta anfitriones y viajeros en todo el territorio nacional. Los propietarios de inmuebles turísticos pueden publicar sus alojamientos para llegar a miles de huéspedes que buscan estancias auténticas, cómodas y seguras. La sede central se encuentra en Barcelona, con presencia especial en Madrid, Valencia, Sevilla, Costa del Sol, Baleares y Canarias.

1.2 Objetivo del Análisis

El objetivo de esta primera fase es comprender la estructura, el origen y el alcance del dataset *Tourist_Accommodation* antes de iniciar cualquier proceso de exploración o limpieza. El análisis buscará responder a necesidades estratégicas del negocio: oferta de alojamientos, calidad de los servicios, patrones de precios y satisfacción de los usuarios.

1.3 Origen y Flujo de los Datos

Según la documentación de onboarding de StaySpain, los datos provienen de tres fuentes principales:

- **Anuncios creados por anfitriones:** tipo de alojamiento, ubicación, servicios y tarifas.
- **Reservas realizadas por viajeros:** fechas, precios y duración de la estancia.
- **Feedback y valoraciones** tras cada estancia.

El flujo de datos sigue el siguiente recorrido: los datos se registran cuando los anfitriones publican sus anuncios o los viajeros realizan reservas; el departamento de IT/Sistemas organiza y estructura la información en tablas dentro del sistema central; y finalmente el equipo de analistas genera reportes sobre oferta, demanda, tendencias de precios y comportamiento de usuarios.

Frecuencia de actualización: Los registros se actualizan semanalmente, lo que tiene implicaciones directas en la gestión de duplicados (ver Sección 3.1.1).

2. Características y Alcance del Dataset

2.1 Dimensiones del Dataset

A continuación se presenta el resumen cuantitativo de la tabla *Tourist_Accommodation*:

Indicador	Valor
Total de registros	7.001
IDs únicos (apartment_id)	6.733
IDs duplicados	268
Duplicados exactos (iguales en todos los campos)	0

2.2 Estructura de la Tabla

La tabla *Tourist_Accommodation* contiene 34 columnas organizadas en los siguientes bloques temáticos. Las descripciones se basan en el diccionario de variables oficial del dataset.

A) Identificación del Alojamiento

Campo	Descripción
apartment_id	Identificación del alojamiento turístico
name	Nombre del alojamiento turístico
description	Descripción detallada del alojamiento turístico
host_id	Número de identificación de la persona que pone a disposición un apartamento turístico

B) Localización

Campo	Descripción
neighbourhood_name	Nombre del barrio donde se encuentra el alojamiento turístico
neighbourhood_district	Nombre del distrito donde se encuentra un alojamiento turístico
country	País en el que se encuentra el alojamiento turístico
city	Ciudad en la que se encuentra el alojamiento turístico

C) Características Físicas

Campo	Descripción
room_type	Tipo de alojamiento turístico
accommodates	Capacidad del apartamento (en personas)
bathrooms	Número de cuartos de baño disponibles en el alojamiento turístico
bedrooms	Número de habitaciones disponibles en el alojamiento turístico
beds	Cantidad de camas disponibles en el alojamiento turístico
amenities_list	Lista de comodidades que presenta el alojamiento turístico

D) Precios y Disponibilidad

Campo	Descripción
price	Precio del alojamiento turístico en euros
minimum_nights	Número de noches mínimas a alquilar del alojamiento turístico
maximum_nights	Número de noches máximas permitidas en el alojamiento turístico
has_availability	Disponibilidad para reservar el alojamiento turístico
availability_30	Días disponibles del alojamiento en un plazo de 30 días desde la fecha de extracción (insert_date)
availability_60	Días disponibles del alojamiento en un plazo de 60 días desde la fecha de extracción
availability_90	Días disponibles del alojamiento en un plazo de 90 días desde la fecha de extracción
availability_365	Días disponibles del alojamiento en un plazo de 365 días desde la fecha de extracción

E) Reseñas y Puntuaciones

Según el diccionario de variables oficial, review_scores_rating se mide de 0 a 100, mientras que el resto de las puntuaciones (accuracy, cleanliness, checkin, communication, location, value) se miden de 0 a 10. Sin embargo, la revisión de los datos almacenados en MySQL muestra valores que no son consistentes con estas escalas declaradas (por ejemplo, valores de 1000 en review_scores_rating o de 100 en campos que deberían ir de 0 a 10). Esta incoherencia entre la escala documentada y la escala almacenada se detalla en la Sección 3.1.3 y deberá investigarse antes de avanzar a la fase de EDA.

Campo	Descripción
number_of_reviews	Número de comentarios que tiene el alojamiento turístico
first_review_date	Fecha del primer comentario del alojamiento turístico
last_review_date	Fecha del último comentario del alojamiento turístico
review_scores_rating	Puntuación de 0 a 100 dada por los usuarios del alojamiento turístico
review_scores_accuracy	Puntuación de 0 a 10 sobre la precisión de los detalles del alojamiento turístico
review_scores_cleanliness	Puntuación de 0 a 10 sobre las condiciones higiénicas del alojamiento turístico
review_scores_checkin	Puntuación de 0 a 10 sobre el momento de entrada al alojamiento turístico
review_scores_communication	Puntuación de 0 a 10 sobre la comunicación del propietario con los usuarios
review_scores_location	Puntuación de 0 a 10 sobre la zona donde se encuentra el alojamiento turístico

Campo	Descripción
review_scores_value	Puntuación de 0 a 10 sobre la evaluación general del alojamiento turístico

F) Metadatos y Comportamiento

Campo	Descripción
is_instant_bookable	Si el alojamiento puede reservarse sin necesidad de revisión por parte del propietario
reviews_per_month	Número de comentarios que recibe el alojamiento turístico al mes
insert_date	Fecha de extracción de la información

3. Limitaciones Identificadas y Áreas de Interés Inicial

3.1 Limitaciones Identificadas

3.1.1 Duplicados No Exactos (268 registros)

Se detectaron 268 registros con `apartment_id` repetido, pero sin duplicados exactos — todos difieren en al menos un campo. Este es el hallazgo más crítico de la fase de Data Understanding.

Una consulta SQL de exploración confirmó el siguiente patrón: los `apartment_id` duplicados aparecen siempre con un número de fechas distintas equivalente al número de apariciones. Esto indica que los duplicados corresponden a instantáneas temporales del mismo alojamiento en diferentes momentos de actualización (snapshots semanales), y no a un error de carga.

apartment_id	total_apariciones	fechas_distintas
14582385	3	3
15402794	3	3
24038577	3	3
144471	2	2
157327	2	2
343864	2	2
503253	2	2
886569	2	2

Esta situación requiere una decisión metodológica antes de continuar con el análisis:

- **Si el objetivo es analizar el estado actual**, se debe conservar solo el registro más reciente por `apartment_id`.

- **Si el objetivo es analizar la evolución temporal**, todos los registros son válidos y el campo `insert_date` actúa como dimensión temporal.

Acción pendiente: Consultar con la directora del departamento cuál es el uso esperado de los datos antes de proceder a la fase de Data Cleaning.

3.1.2 Valores Nulos — Exploración y Verificación

La exploración realizada mediante Python/pandas en Visual Studio Code permitió obtener el siguiente mapa de nulos del dataset:

Campo	Nulos	% Nulos	Tipo de nulo	Impacto estimado
<code>neighbourhood_district</code>	2.760	39,42%	Localización incompleta	MUY ALTO
<code>review_scores_value</code>	1.342	19,17%	Sin reseñas aún	ALTO
<code>review_scores_location</code>	1.342	19,17%	Sin reseñas aún	Alto
<code>review_scores_checkin / accuracy / communication / cleanliness / rating</code>	~1.327-1.341	~19%	Sin reseñas aún	Alto
<code>first_review_date / last_review_date / reviews_per_month</code>	~1.254	17,91%	Sin historial	Medio
<code>has_availability</code>	550	7,86%	Error de carga (booleano)	MEDIO — anomalía de sistema
<code>price / bathrooms / bedrooms / description / amenities_list / name / beds</code>	3-131	<2%	Dato faltante / texto ausente	Bajo-Medio

Hallazgo clave: los nulos de reseñas son estructurales, no aleatorios

La exploración en VSC confirmó que los valores nulos de los campos `review_scores_*` son consistentes entre sí: cuando un alojamiento carece de puntuación en una categoría, carece de puntuación en todas ellas. Esto indica que los nulos corresponden a alojamientos que nunca han recibido una reseña, y no a errores de registro.

Este hallazgo fue verificado directamente con la siguiente consulta SQL:

```
SELECT COUNT(*) AS total_sin_resenas,
  ROUND(COUNT(*) * 100.0 / (SELECT COUNT(*) FROM Tourist_Accommodation), 2)
  AS porcentaje
FROM Tourist_Accommodation
WHERE number_of_reviews = 0 OR number_of_reviews IS NULL;
```

Resultado obtenido: 1.251 registros (17,87%). Esta cifra es coherente con los nulos detectados en los campos de fecha y puntuación (~17,91%). La diferencia de 3 registros entre ambas métricas revela una inconsistencia menor: existen alojamientos con número de

reseñas igual a cero pero con fecha de reseña registrada, o viceversa. Estos 3 casos deberán resolverse en la fase de Data Cleaning.

Recomendación: tratar los alojamientos sin reseñas como un subgrupo diferenciado en la fase de Data Cleaning, en lugar de aplicar imputación de valores. Esto evitará sesgos en el análisis de satisfacción.

Nota sobre has_availability

Se tiene que investigar por qué hay 550 nulos de has_availability. Sería conveniente entender si no hay disponibilidad porque el alojamiento ya no está activo en el Portal o por otra razón.

3.1.3 Aspectos de Formato Pendientes de Verificación

Durante la fase de Data Understanding no se han ejecutado verificaciones de formato sobre todos los campos. Los siguientes aspectos se identifican como sospechosos a partir del conocimiento del tipo de dato esperado y de la revisión visual del dataset, y deberán confirmarse o descartarse en la fase de EDA:

- **price:** el diccionario confirma que el valor está expresado en euros; queda pendiente verificar si está almacenado como tipo numérico o como string con símbolo de moneda.
- **amenities_list:** campo de texto aparentemente complejo o serializado. Pendiente de evaluar si requiere parsing para ser analizable.
- **has_availability / is_instant_bookable:** pendiente de confirmar el formato exacto almacenado (booleano nativo, entero 0/1, o string 't'/'f').
- **Escalas de review_scores_***: el diccionario oficial declara review_scores_rating en escala 0-100 y el resto de las puntuaciones en escala 0-10. La revisión de los datos en MySQL mostró valores incoherentes con estas escalas (por ejemplo, 1000 en review_scores_rating y 100 en campos declarados de 0-10). El factor exacto de esta discrepancia aún no está claro y debe investigarse en la fase de EDA antes de definir cualquier transformación o normalización.
- **Campos de fecha (first_review_date, last_review_date, insert_date):** pendiente de validar consistencia de formato y compatibilidad con operaciones temporales en MySQL.

Importante: Las observaciones anteriores son hipótesis de trabajo basadas en la revisión del esquema y el tipo de dato declarado, no en verificaciones ejecutadas. Su confirmación o descarte forma parte de la fase de EDA.

3.2 Áreas de Interés Inicial

Con base en el análisis del dataset y los objetivos de negocio de StaySpain, se proponen las siguientes áreas de investigación prioritarias:

Área de interés	Descripción	Relevancia
Análisis de precios	Distribución de precios por ciudad, barrio y tipo de alojamiento	Alta
Satisfacción de usuarios	Correlación entre puntuaciones de reseña y características del alojamiento, una vez aclarada la escala real de cada campo	Alta
Disponibilidad y demanda	Patrones de availability_30/60/90/365 por zona	Alta
Calidad del dataset	Cobertura y completitud de campos de reseñas	Alta
Segmentación por madurez	Separar alojamientos con y sin reseñas para evitar sesgos en el análisis de satisfacción	Alta
Perfil de anfitriones	Concentración de alojamientos por host_id	Media
Evolución temporal	Cambios en precios y reseñas según insert_date	Media
